

**Análise de preços de casas nos EUA usando EDA, feature engineering, modelos supervisionados e não supervisionados.**

**1458**

registros após tratamento

**298**

features processadas

**0,817**

$R^2$  regressão múltipla

**92,1%**

acurácia classificação

Grupo: Vitor, Luis Felipe, Emanuel, Rogeres, Alessandro e Natalia

**Vitor**

EDA, Feature Engineering, integração e organização

**Luis Felipe**

Regressão linear simples e múltipla

**Emanuel**

Classificação: Regressão Logística e Random Forest

**Rogeres**

Clusterização, PCA e t-SNE

**Alessandro**

Apriori e Local Outlier Factor

**Natalia**

Visualização de dados e storytelling

**1**

EDA e limpeza

**2**

Feature  
engineering

**3**

Regressão

**4**

Classificação

**5**



Clusterização

**6**

Associação,  
outliers e  
storytelling

**Pergunta-guia: quais fatores estruturais e qualitativos mais ajudam a explicar ou prever o preço de venda?**

- Base original: 1460 linhas e 81 variáveis
- Alvo do problema: SalePrice
- Tratamento de nulos com imputação por mediana/moda
- Remoção de outliers clássicos em GrLivArea x SalePrice
- Normalização de numéricas e One-Hot Encoding de categóricas



- TotalSF: área total combinando porão e pavimentos
- TotalBathrooms: banheiros completos e lavabos
- HouseAge e YearsSinceRemodel: idade e atualização do imóvel
- HasGarage, HasBasement, HasFireplace e HasPool: atributos estruturais
- Base final processada: 1458 linhas x 298 colunas

## Features criadas

As novas variáveis condensam sinais imobiliários relevantes: tamanho, conforto, idade, conservação e presença de estruturas valorizadas.

0,492


$R^2$  regressão simples

0,817


$R^2$  regressão múltipla

- Modelo simples: GrLivArea -> SalePrice
- Modelo múltiplo: top 10 features por correlação
- TotalSF e TotalBathrooms entraram entre os principais preditores
- Métricas usadas: MAE, RMSE e  $R^2$

Comparação de Métricas — Regressão Simples vs Múltipla



Preditos vs Reais



- SalePrice convertido em classe binária pela mediana
- 0 = abaixo da mediana; 1 = acima da mediana
- Modelos: Regressão Logística e Random Forest
- Métricas: Accuracy, Precision, Recall, F1 e matriz de confusão


**92,1%**

Accuracy Reg. Logística



**0,922**

F1 Reg. Logística



Comparação de Métricas — Regressão Logística vs Random Forest




Matrizes de Confusão — Comparação dos Modelos



- K-Means para encontrar perfis de imóveis sem usar o preço no treino
- Elbow Method apoiou a escolha de k
- PCA e t-SNE usados para visualização em 2D
- PCA explicou 29,5% da variância nas duas primeiras componentes
- Silhouette Score: 0,1520, positivo mas com sobreposição natural








- Apriori exigiu binarização das variáveis em tags interpretáveis
- Regras avaliadas por suporte, confiança e lift
- Associações fortes envolveram casas grandes, bairros premium e garagens maiores
- LOF identificou 73 outliers, cerca de 5% da base
- Outliers ajudam a entender casos extremos que podem distorcer modelos



- Distribuições mostram assimetria à direita em SalePrice
- Heatmap confirma variáveis mais ligadas ao preço
- Scatter e boxplot reforçam impacto de área e qualidade
- Painel consolidado transforma métricas em narrativa analítica

**Mensagem visual: preço é resultado da combinação entre tamanho, qualidade, estrutura e idade do imóvel.**



**1458 x 298**

base final

**0,817**

$R^2$  regressão

**92,1%**

accuracy classificação

**73**

outliers LOF

- O preço não depende de uma única variável
- Qualidade geral, área total, área habitável, banheiros, garagem e idade são sinais centrais
- Feature engineering melhorou a interpretação e alimentou melhor os modelos
- Modelos supervisionados tiveram forte poder preditivo
- Modelos não supervisionados revelaram perfis e anomalias úteis

**Obrigado!**